

Solusi Kuis 2

Intelligensi Artificial (IF3170)

Semester I 2025/2026

15 Desember 2025

IF '23

Razi Rachman Widyadhana - @zirachw

Apabila terdapat kesalahan pada file, silakan kontak penulis :)

Dilarang membawa Hardcopy saat ujian berlangsung

This page intentionally left blank

Daftar Isi

1	Kuis 2 Tahun 2025/2026	4
	Bagian 1 K-NN dan Linear Regression (Nilai 35)	5
	Bagian 2 LogRes dan DTL (Nilai 35)	7
	Bagian 3 Isu dalam DTL (Nilai 30)	13

Kuis 2 Tahun 2025/2026

Bagian 1 K-NN dan Linear Regression	
(Nilai 35)	5
Bagian 2 LogRes dan DTL (Nilai 35) . . .	7
Bagian 3 Isu dalam DTL (Nilai 30)	13

Bagian 1 K-NN dan Linear Regression (Nilai 35)**Soal 1: K-NN (bobot 15)**

Diketahui data latih sebagai berikut:

No	X1	X2	Y
1	2	4	B
2	3	5	A
3	1	2	A
4	7	8	B
5	6	7	B
6	8	7	B
7	2	3	A
8	9	6	B
9	4	4	A
10	5	5	B

Terdapat sebuah data baru dengan nilai X1 adalah 4 dan X2 adalah 3. Tuliskan rumus penghitungan jarak menggunakan manhattan distance dan hitung jarak (hingga desimal 3) antara data latih dengan data baru menggunakan manhattan distance tsb. Jika menggunakan nilai K=3, tuliskan data latih mana saja yang terpilih untuk menjadi nearest neighbour dan tetapkan nilai kelas (Y) dari data baru tersebut.

Jawab:

Rumus Manhattan Distance:

$$d(p, q) = |x_1 - x'_1| + |x_2 - x'_2|$$

dimana (x_1, x_2) adalah koordinat data latih dan (x'_1, x'_2) adalah koordinat data baru (4, 3).

Perhitungan Jarak:

No	X1	X2	Y	Perhitungan	Jarak
1	2	4	B	$ 2 - 4 + 4 - 3 = 2 + 1$	3.000
2	3	5	A	$ 3 - 4 + 5 - 3 = 1 + 2$	3.000
3	1	2	A	$ 1 - 4 + 2 - 3 = 3 + 1$	4.000
4	7	8	B	$ 7 - 4 + 8 - 3 = 3 + 5$	8.000
5	6	7	B	$ 6 - 4 + 7 - 3 = 2 + 4$	6.000
6	8	7	B	$ 8 - 4 + 7 - 3 = 4 + 4$	8.000
7	2	3	A	$ 2 - 4 + 3 - 3 = 2 + 0$	2.000
8	9	6	B	$ 9 - 4 + 6 - 3 = 5 + 3$	8.000
9	4	4	A	$ 4 - 4 + 4 - 3 = 0 + 1$	1.000
10	5	5	B	$ 5 - 4 + 5 - 3 = 1 + 2$	3.000

Pengurutan Jarak (dari terkecil):

1. Data No. 9: jarak = 1.000, kelas = A
2. Data No. 7: jarak = 2.000, kelas = A
3. Data No. 1: jarak = 3.000, kelas = B

Untuk K=3:

Data yang terpilih sebagai nearest neighbour adalah: **Data No. 9, Data No. 7, dan Data No. 1**

Voting kelas:

- Kelas A: 2 suara (dari data no. 9 dan 7)

- Kelas B: 1 suara (dari data no. 1)

Kesimpulan: Kelas yang diprediksi untuk data baru ($X_1=4$, $X_2=3$) adalah **A**

Soal 2: Linear Regression untuk Klasifikasi (bobot 20)

Diketahui hipotesis linear regression yang mewakili data latih (untuk klasifikasi) adalah

$$y = -0.313 + 0.051 X_1 + 0.132 X_2$$

dengan aturan jika $y < 0.5$ maka diprediksi sebagai kelas A.

Untuk 10 data latih di atas, buatlah confusion matrix dan tuliskan nilai Precision, Recall, dan F-1 Score untuk kelas B (diasumsikan sebagai kelas positif). Tuliskan jawaban hasil perhitungan hingga desimal 3.

Jawab:

Perhitungan Prediksi untuk setiap data:

No	X1	X2	Y Aktual	Perhitungan	y	Prediksi
1	2	4	B	$-0.313 + 0.051(2) + 0.132(4)$	0.317	A
2	3	5	A	$-0.313 + 0.051(3) + 0.132(5)$	0.500	B
3	1	2	A	$-0.313 + 0.051(1) + 0.132(2)$	0.002	A
4	7	8	B	$-0.313 + 0.051(7) + 0.132(8)$	1.100	B
5	6	7	B	$-0.313 + 0.051(6) + 0.132(7)$	0.917	B
6	8	7	B	$-0.313 + 0.051(8) + 0.132(7)$	0.819	B
7	2	3	A	$-0.313 + 0.051(2) + 0.132(3)$	0.185	A
8	9	6	B	$-0.313 + 0.051(9) + 0.132(6)$	0.838	B
9	4	4	A	$-0.313 + 0.051(4) + 0.132(4)$	0.419	A
10	5	5	B	$-0.313 + 0.051(5) + 0.132(5)$	0.602	B

Confusion Matrix (Kelas B sebagai Positif):

		Prediksi	
		B	A
Aktual	B	5	1
	A	1	3

dimana:

- True Positive (TP) = 5
- False Positive (FP) = 1
- False Negative (FN) = 1
- True Negative (TN) = 3

Perhitungan Metrik:

Precision:

$$\text{Precision} = \frac{TP}{TP + FP} = \frac{5}{5 + 1} = \frac{5}{6} = 0.833$$

Recall:

$$\text{Recall} = \frac{TP}{TP + FN} = \frac{5}{5 + 1} = \frac{5}{6} = 0.833$$

F-1 Score:

$$F-1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} = 2 \times \frac{0.833 \times 0.833}{0.833 + 0.833} = 0.833$$

Kesimpulan:

- Precision = 0.833
- Recall = 0.833
- F-1 Score = 0.833

Bagian 2 LogRes dan DTL (Nilai 35)**Soal 1: Logistic Regression (Nilai 20)**

Seorang mahasiswa diminta melakukan proses pembelajaran dengan Logistic Regression untuk mendapatkan bobot w_0 , w_1 , w_2 sebanyak 1 iterasi. Gunakan: bobot awal w_0 dan w_2 sebesar 0, nilai bias 1 learning rate 0.3. Urutan instance pembelajaran hasil pemilihan random adalah 3, 1, 4, 2.

No	x1	x2	kelas y
1	0.5	0	0
2	0	1	0
3	0	-1	1
4	1	-0.5	1

- Tuliskan langkah pelatihan model dengan lengkap disertai rumus dan cara perhitungan. Gunakan ketelitian minimal 3 angka di belakang koma. Tuliskan bobot akhir hasil pelatihan. (Nilai 15)
- Hitung akurasi model pelatihan. (Nilai 5)

Jawab:

- Langkah Pelatihan Model

Inisialisasi:

- Bobot awal: $w_0 = 0$, $w_1 = 0$, $w_2 = 0$
- Learning rate: $\alpha = 0.3$
- Urutan pembelajaran: instance 3, 1, 4, 2

Rumus yang digunakan:

Fungsi sigmoid:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Perhitungan z:

$$z = w_0 \cdot 1 + w_1 \cdot x_1 + w_2 \cdot x_2$$

Update bobot:

$$w_j := w_j + \alpha \cdot (y - \hat{y}) \cdot x_j$$

dimana $\hat{y} = \sigma(z)$

Instance 1: Data No. 3 (x1=0, x2=-1, y=1)

- $z = 0 \cdot 1 + 0 \cdot 0 + 0 \cdot (-1) = 0$
- $\hat{y} = \sigma(0) = \frac{1}{1+e^0} = 0.500$
- Error: $y - \hat{y} = 1 - 0.500 = 0.500$
- Update:
 - * $w_0 = 0 + 0.3 \cdot 0.500 \cdot 1 = 0.150$
 - * $w_1 = 0 + 0.3 \cdot 0.500 \cdot 0 = 0.000$
 - * $w_2 = 0 + 0.3 \cdot 0.500 \cdot (-1) = -0.150$

Bobot setelah instance 3: $w_0 = 0.150, w_1 = 0.000, w_2 = -0.150$

Instance 2: Data No. 1 (x1=0.5, x2=0, y=0)

- $z = 0.150 \cdot 1 + 0.000 \cdot 0.5 + (-0.150) \cdot 0 = 0.150$
- $\hat{y} = \sigma(0.150) = \frac{1}{1+e^{-0.150}} = 0.537$
- Error: $y - \hat{y} = 0 - 0.537 = -0.537$
- Update:
 - * $w_0 = 0.150 + 0.3 \cdot (-0.537) \cdot 1 = -0.011$
 - * $w_1 = 0.000 + 0.3 \cdot (-0.537) \cdot 0.5 = -0.081$
 - * $w_2 = -0.150 + 0.3 \cdot (-0.537) \cdot 0 = -0.150$

Bobot setelah instance 1: $w_0 = -0.011, w_1 = -0.081, w_2 = -0.150$

Instance 3: Data No. 4 (x1=1, x2=-0.5, y=1)

- $z = -0.011 \cdot 1 + (-0.081) \cdot 1 + (-0.150) \cdot (-0.5) = -0.011 - 0.081 + 0.075 = -0.017$
- $\hat{y} = \sigma(-0.017) = \frac{1}{1+e^{0.017}} = 0.496$
- Error: $y - \hat{y} = 1 - 0.496 = 0.504$
- Update:
 - * $w_0 = -0.011 + 0.3 \cdot 0.504 \cdot 1 = 0.140$
 - * $w_1 = -0.081 + 0.3 \cdot 0.504 \cdot 1 = 0.070$
 - * $w_2 = -0.150 + 0.3 \cdot 0.504 \cdot (-0.5) = -0.226$

Bobot setelah instance 4: $w_0 = 0.140, w_1 = 0.070, w_2 = -0.226$

Instance 4: Data No. 2 (x1=0, x2=1, y=0)

- $z = 0.140 \cdot 1 + 0.070 \cdot 0 + (-0.226) \cdot 1 = 0.140 + 0 - 0.226 = -0.086$
- $\hat{y} = \sigma(-0.086) = \frac{1}{1+e^{0.086}} = 0.479$
- Error: $y - \hat{y} = 0 - 0.479 = -0.479$
- Update:
 - * $w_0 = 0.140 + 0.3 \cdot (-0.479) \cdot 1 = -0.004$
 - * $w_1 = 0.070 + 0.3 \cdot (-0.479) \cdot 0 = 0.070$
 - * $w_2 = -0.226 + 0.3 \cdot (-0.479) \cdot 1 = -0.370$

Bobot Akhir Hasil Pelatihan:

$$w_0 = -0.004, \quad w_1 = 0.070, \quad w_2 = -0.370$$

b. Perhitungan Akurasi Model

Menggunakan bobot akhir untuk memprediksi semua data:

No	x1	x2	y	z	$\hat{y}$	Prediksi	Benar?
1	0.5	0	0	$-0.004 + 0.035 + 0 = 0.031$	0.508	1	Tidak
2	0	1	0	$-0.004 + 0 - 0.370 = -0.374$	0.408	0	Ya
3	0	-1	1	$-0.004 + 0 + 0.370 = 0.366$	0.590	1	Ya
4	1	-0.5	1	$-0.004 + 0.070 + 0.185 = 0.251$	0.562	1	Ya

Keterangan: Prediksi = 1 jika $\hat{y} \geq 0.5$, Prediksi = 0 jika $\hat{y} < 0.5$

Jumlah prediksi benar: 3 dari 4 data

Akurasi:

$$\text{Akurasi} = \frac{\text{Jumlah Prediksi Benar}}{\text{Total Data}} = \frac{3}{4} = 0.75 = \boxed{75\%}$$

Soal 2: Decision Tree Learning (Nilai 15)

Buatlah model pembelajaran Decision Tree Learning dari dataset berikut dengan split criteria Information Gain, untuk kelas target Belanja. Tanpa langkah penjelasan dan rumus, jawaban tidak akan dinilai. (Nilai 15)

No	Stok Barang	Cuaca	Bekerja	Belanja
D1	Rendah	Cerah	Ya	Ya
D2	Tinggi	Cerah	Ya	Tidak
D3	Sedang	Berawan	Ya	Tidak
D4	Rendah	Hujan	Ya	Tidak
D5	Rendah	Berawan	Tidak	Ya
D6	Tinggi	Cerah	Tidak	Tidak
D7	Tinggi	Hujan	Tidak	Tidak
D8	Sedang	Berawan	Ya	Tidak
D9	Rendah	Hujan	Ya	Tidak
D10	Rendah	Hujan	Tidak	Ya
D11	Sedang	Cerah	Tidak	Ya
D12	Tinggi	Cerah	Ya	Tidak

Jawab:

Langkah 1: Hitung Entropy Dataset (S)

Dataset memiliki:

- Ya (Belanja): 4 instance (D1, D5, D10, D11)
- Tidak (Belanja): 8 instance (D2, D3, D4, D6, D7, D8, D9, D12)
- Total: 12 instance

Rumus Entropy:

$$E(S) = - \sum_i p_i \log_2(p_i)$$

Perhitungan:

$$\begin{aligned} E(S) &= -\frac{4}{12} \log_2 \left(\frac{4}{12} \right) - \frac{8}{12} \log_2 \left(\frac{8}{12} \right) \\ E(S) &= -\frac{1}{3} \log_2 \left(\frac{1}{3} \right) - \frac{2}{3} \log_2 \left(\frac{2}{3} \right) \\ E(S) &= -\frac{1}{3}(-1.585) - \frac{2}{3}(-0.585) = 0.528 + 0.390 = \boxed{0.918} \end{aligned}$$

Langkah 2: Hitung Information Gain untuk Setiap Atribut

2.1. Atribut: Stok Barang

Rendah (D1, D4, D5, D9, D10): 5 instance

- Ya: 3 (D1, D5, D10)
- Tidak: 2 (D4, D9)
- $E(\text{Rendah}) = -\frac{3}{5} \log_2 \left(\frac{3}{5}\right) - \frac{2}{5} \log_2 \left(\frac{2}{5}\right)$
- $E(\text{Rendah}) = 0.442 + 0.529 = 0.971$

Sedang (D3, D8, D11): 3 instance

- Ya: 1 (D11)
- Tidak: 2 (D3, D8)
- $E(\text{Sedang}) = -\frac{1}{3} \log_2 \left(\frac{1}{3}\right) - \frac{2}{3} \log_2 \left(\frac{2}{3}\right)$
- $E(\text{Sedang}) = 0.528 + 0.390 = 0.918$

Tinggi (D2, D6, D7, D12): 4 instance

- Ya: 0
- Tidak: 4 (D2, D6, D7, D12)
- $E(\text{Tinggi}) = 0$ (murni, semua Tidak)

$$\begin{aligned}
 \text{Gain}(S, \text{Stok Barang}) &= E(S) - \sum_v \frac{|S_v|}{|S|} E(S_v) \\
 &= 0.918 - \left(\frac{5}{12} \cdot 0.971 + \frac{3}{12} \cdot 0.918 + \frac{4}{12} \cdot 0 \right) \\
 &= 0.918 - (0.404 + 0.230 + 0) = 0.918 - 0.634 = \boxed{0.284}
 \end{aligned}$$

2.2. Atribut: Cuaca

Cerah (D1, D2, D6, D11, D12): 5 instance

- Ya: 2 (D1, D11)
- Tidak: 3 (D2, D6, D12)
- $E(\text{Cerah}) = -\frac{2}{5} \log_2 \left(\frac{2}{5}\right) - \frac{3}{5} \log_2 \left(\frac{3}{5}\right)$
- $E(\text{Cerah}) = 0.529 + 0.442 = 0.971$

Berawan (D3, D5, D8): 3 instance

- Ya: 1 (D5)
- Tidak: 2 (D3, D8)
- $E(\text{Berawan}) = -\frac{1}{3} \log_2 \left(\frac{1}{3}\right) - \frac{2}{3} \log_2 \left(\frac{2}{3}\right)$
- $E(\text{Berawan}) = 0.528 + 0.390 = 0.918$

Hujan (D4, D7, D9, D10): 4 instance

- Ya: 1 (D10)
- Tidak: 3 (D4, D7, D9)

- $E(\text{Hujan}) = -\frac{1}{4} \log_2 \left(\frac{1}{4}\right) - \frac{3}{4} \log_2 \left(\frac{3}{4}\right)$
- $E(\text{Hujan}) = 0.500 + 0.311 = 0.811$

$$\begin{aligned} \text{Gain}(S, \text{Cuaca}) &= 0.918 - \left(\frac{5}{12} \cdot 0.971 + \frac{3}{12} \cdot 0.918 + \frac{4}{12} \cdot 0.811 \right) \\ &= 0.918 - (0.404 + 0.230 + 0.270) = 0.918 - 0.904 = \boxed{0.014} \end{aligned}$$

2.3. Atribut: Bekerja

Ya (D1, D2, D3, D4, D8, D9, D12): 7 instance

- Ya: 1 (D1)
- Tidak: 6 (D2, D3, D4, D8, D9, D12)
- $E(\text{Ya}) = -\frac{1}{7} \log_2 \left(\frac{1}{7}\right) - \frac{6}{7} \log_2 \left(\frac{6}{7}\right)$
- $E(\text{Ya}) = 0.407 + 0.191 = 0.598$

Tidak (D5, D6, D7, D10, D11): 5 instance

- Ya: 3 (D5, D10, D11)
- Tidak: 2 (D6, D7)
- $E(\text{Tidak}) = -\frac{3}{5} \log_2 \left(\frac{3}{5}\right) - \frac{2}{5} \log_2 \left(\frac{2}{5}\right)$
- $E(\text{Tidak}) = 0.442 + 0.529 = 0.971$

$$\begin{aligned} \text{Gain}(S, \text{Bekerja}) &= 0.918 - \left(\frac{7}{12} \cdot 0.598 + \frac{5}{12} \cdot 0.971 \right) \\ &= 0.918 - (0.349 + 0.404) = 0.918 - 0.753 = \boxed{0.165} \end{aligned}$$

Langkah 3: Pilih Atribut Root

Atribut	Information Gain
Stok Barang	0.284
Cuaca	0.014
Bekerja	0.165

Root Node: Stok Barang (Gain tertinggi = 0.284)

Langkah 4: Bangun Pohon dari Root

Cabang Stok Barang = Tinggi: (D2, D6, D7, D12)

- Semua instance adalah Tidak (murni)
- **Leaf node: Tidak**

Cabang Stok Barang = Sedang: (D3, D8, D11)

- Ya: 1 (D11), Tidak: 2 (D3, D8)
- Perlu split lagi

Hitung Gain untuk subset Sedang ($E(\text{Sedang}) = 0.918$):

Atribut Cuaca untuk Sedang:

- Cerah (D11): $Y_a=1$, $Tidak=0 \rightarrow E = 0$
- Berawan (D3, D8): $Y_a=0$, $Tidak=2 \rightarrow E = 0$

$$\text{Gain}(\text{Sedang}, \text{Cuaca}) = 0.918 - \left(\frac{1}{3} \cdot 0 + \frac{2}{3} \cdot 0 \right) = 0.918$$

Atribut Bekerja untuk Sedang:

- Ya (D3, D8): $Y_a=0$, $Tidak=2 \rightarrow E = 0$
- Tidak (D11): $Y_a=1$, $Tidak=0 \rightarrow E = 0$

$$\text{Gain}(\text{Sedang}, \text{Bekerja}) = 0.918 - 0 = 0.918$$

Pilih Cuaca (atau Bekerja, keduanya sama). Gunakan **Cuaca**:

- Cuaca = Cerah $\rightarrow$ **Leaf: Ya**
- Cuaca = Berawan $\rightarrow$ **Leaf: Tidak**

Cabang Stok Barang = Rendah: (D1, D4, D5, D9, D10)

- Ya: 3 (D1, D5, D10), Tidak: 2 (D4, D9)
- Perlu split lagi

Hitung Gain untuk subset Rendah ($E(\text{Rendah}) = 0.971$):

Atribut Cuaca untuk Rendah:

- Cerah (D1): $Y_a=1$, $Tidak=0 \rightarrow E = 0$
- Berawan (D5): $Y_a=1$, $Tidak=0 \rightarrow E = 0$
- Hujan (D4, D9, D10): $Y_a=1$, $Tidak=2 \rightarrow E = -\frac{1}{3} \log_2 \frac{1}{3} - \frac{2}{3} \log_2 \frac{2}{3} = 0.918$

$$\begin{aligned} \text{Gain}(\text{Rendah}, \text{Cuaca}) &= 0.971 - \left(\frac{1}{5} \cdot 0 + \frac{1}{5} \cdot 0 + \frac{3}{5} \cdot 0.918 \right) \\ &= 0.971 - 0.551 = 0.420 \end{aligned}$$

Atribut Bekerja untuk Rendah:

- Ya (D1, D4, D9): $Y_a=1$, $Tidak=2 \rightarrow E = 0.918$
- Tidak (D5, D10): $Y_a=2$, $Tidak=0 \rightarrow E = 0$

$$\begin{aligned} \text{Gain}(\text{Rendah}, \text{Bekerja}) &= 0.971 - \left(\frac{3}{5} \cdot 0.918 + \frac{2}{5} \cdot 0 \right) \\ &= 0.971 - 0.551 = 0.420 \end{aligned}$$

Pilih Bekerja (atau Cuaca, keduanya sama). Gunakan **Bekerja**:

- Bekerja = Tidak $\rightarrow$ **Leaf: Ya**

- Bekerja = Ya $\rightarrow$ subset (D1, D4, D9), perlu split lagi

Untuk subset (D1, D4, D9) - Ya:1, Tidak:2, hanya tersisa atribut Cuaca:

- Cerah (D1): Ya=1, Tidak=0 $\rightarrow$ **Leaf: Ya**
- Hujan (D4, D9): Ya=0, Tidak=2 $\rightarrow$ **Leaf: Tidak**

Decision Tree yang Dihasilkan:



Bagian 3 Isu dalam DTL (Nilai 30)

Terdapat dataset S sebagai berikut:

Tabel 1. Dataset S

Instance	A	B	C	D	Kelas
1	a3	17	c2	d9	N
2	a3	19	c3	d7	Y
3	a3	25	c1	d1	Y
4	a3	21	?	d4	N
5	a3	26	c1	d5	Y
6	a3	18	c2	d3	N
7	a3	23	c3	d8	Y
8	a3	21	c2	d2	N
9	a3	21	c3	d6	N

Keterangan:

- nilai ? menandakan *missing value*;
- Atribut A memiliki 3 kemungkinan nilai (a1, a2, a3);
- Atribut B berisi nilai kontinyu.
- Atribut C memiliki 3 kemungkinan nilai (c1, c2, c3);
- Atribut D memiliki 9 kemungkinan nilai (d1 - d9);
- Terdapat dua kelas (Y, N).

Tuliskan jawaban dari setiap pertanyaan berikut ini pada kolom yang disediakan.

No	Pertanyaan
1.	Tentukan formula untuk menentukan entropi dari dataset S di Tabel 1, dengan kondisi <i>missing value</i> tetap tidak diisikan nilai apapun. Tuliskan formula dengan angka yang terlibat dengan detil dan tidak hanya hasil akhirnya. (Nilai 3)

No	Pertanyaan
2.	Jika ingin dicari atribut yang akan menjadi akar (root) dari pohon keputusan dengan DTL untuk dataset S di Tabel 1, maka berapa banyak nilai <i>gain</i> yang harus dihitung. Jelaskan nilai <i>gain</i> untuk atribut apa saja, tidak perlu dihitung nilai <i>gain</i> nya. (Nilai 3)

No	Pertanyaan
3.	Jika nilai missing value di Atribut C tetap kosong, tentukan nilai <i>gain ratio</i> dari atribut C. Tuliskan dengan lengkap semua formula (angka-angka yang terlibat) untuk menghitung <i>gain ratio</i> atribut C. (Nilai 6)

No	Pertanyaan
4.	Jika nilai missing value di Atribut C diisi dengan nilai c1, bagaimanakah nilai SplitInformation untuk Atribut A, dan dampaknya pada Gain Ratio Atribut A? Jelaskan, Idak perlu dihitung gain ratio atribut A. (Nilai 6)

No	Pertanyaan
5.	Jika atribut C terpilih sebagai simpul akar dalam pembentukan pohon keputusan (dengan missing value tetap dibiarkan kosong), gambarkanlah pencabangan di bawah simpul akar C, lengkapi dengan nilai pada tiap cabang, dan data yang berada di tiap pencabangan beserta bobot untuk tiap <i>instance</i> nya sesuai algoritma C4.5. (Nilai 6)

No	Pertanyaan
6.	Jika pemilihan atribut pada dataset S di Tabel 1 untuk menjadi simpul pada pohon keputusan menggunakan formula $\frac{Gain(S, Atribut)}{Cost(Atribut)}$; dan cost dari Atribut B jauh lebih besar dibandingkan dengan cost atribut lain, maka apakah atribut B tidak akan pernah terpilih sebagai simpul pembentuk pohon? Jelaskan dengan singkat. (Nilai 3)

No	Pertanyaan
7.	Jika pohon keputusan yang dihasilkan untuk suatu dataset lain dengan 100 instance dan 55 kelas Y dan 45 kelas N (bukan dataset di Tabel 1) adalah sebagai berikut, kemudian akan dilakukan post-pruning, apa hasil dari pruning dengan menghapus atribut A1 sebagai prekondisi, tanpa mengubah ke decision rule? Jelaskan dengan singkat, tanpa perlu mempertimbangkan kinerja model sebelum atau sesudah pruning. (Nilai 3) <pre> A / \ a1_1 a1_3 / \ Y N A / \ a2_1 a2_2 / \ N Y </pre>

Jawab:

1. Formula Entropi Dataset S

Dataset S memiliki 9 instance total. Untuk perhitungan entropi dengan missing value tetap kosong, kita hitung hanya dari instance dengan kelas yang diketahui (semua instance memiliki kelas, jadi 9 instance). Namun jika mengikuti aturan handling missing value yang ketat, distribusi kelas dari 8 instance dengan nilai C diketahui: Y = 4 instance (instance 2, 3, 5, 7), N = 4 instance (instance 1, 6, 8, 9).

Formula entropi:

$$E(S) = -\frac{4}{8} \log_2 \left(\frac{4}{8} \right) - \frac{4}{8} \log_2 \left(\frac{4}{8} \right)$$

2. Berapa Banyak Nilai Gain yang Harus Dihitung

Untuk menentukan atribut root, perlu menghitung gain untuk setiap atribut yang tersedia.

Atribut A: Semua 9 instance memiliki nilai a3 (tidak ada variasi). Gain = 0, tidak perlu dihitung.

Atribut B: Nilai kontinyu, perlu diskretisasi dengan mencari breakpoint di mana kelas target berubah. Urutkan data berdasarkan B:

- B=17 (N), B=18 (N), B=19 (Y) → breakpoint: $(18+19)/2 = 18.5$
- B=19 (Y), B=21 (N,N,N) → breakpoint: $(19+21)/2 = 20$
- B=21 (N,N,N), B=23 (Y) → breakpoint: $(21+23)/2 = 22$
- B=23 (Y), B=25 (Y), B=26 (Y) → tidak ada breakpoint

Total ada 3 breakpoint, sehingga perlu 3 perhitungan gain untuk atribut B.

Atribut C: Memiliki 3 nilai (c1, c2, c3) dengan 1 missing value, perlu 1 perhitungan gain.

Atribut D: Memiliki 9 kemungkinan nilai (d1-d9), namun dalam dataset setiap instance memiliki nilai D yang berbeda-beda. Perlu 1 perhitungan gain.

Kesimpulan: Berapa banyak nilai gain yang harus dihitung = $\boxed{5}$

(3 untuk atribut B dengan breakpoint 18.5, 20, 22 + 1 untuk atribut C + 1 untuk atribut D)

Nilai gain yang harus dihitung:

- Gain(S, B) dengan breakpoint 18.5, 20, 22 (3 perhitungan)
- Gain(S, C) (1 perhitungan)
- Gain(S, D) (1 perhitungan)

3. Gain Ratio Atribut C Berdasarkan aturan handling missing value, perhitungan gain menggunakan formula:

$$\text{Gain}(S, A) = \frac{|S_{\text{known}}|}{|S|} \times \left(E(S) - \sum_v \frac{|S_v|}{|S_{\text{known}}|} E(S_v) \right)$$

Dataset S dengan nilai C diketahui: 8 instance, Y = 4, N = 4 $E(S) = -\frac{4}{8} \log_2 \frac{4}{8} - \frac{4}{8} \log_2 \frac{4}{8} = 1.0$

Untuk Atribut C:

- Instance dengan nilai diketahui: 8 instance (c1: 2, c2: 3, c3: 3)
- Instance dengan missing value: 1 instance
- $|S_{\text{known}}| = 8, |S| = 9$

Entropi setiap subset (hanya yang diketahui):

- $E(c1) = 0$ (Y:2, N:0)
- $E(c2) = 0$ (Y:0, N:3)
- $E(c3) = -\frac{2}{3} \log_2 \frac{2}{3} - \frac{1}{3} \log_2 \frac{1}{3} = 0.918$ (Y:2, N:1)

Information Gain:

$$\begin{aligned}
 \text{Gain}(S, C) &= \frac{8}{9} \times \left(E(S) - \left(\frac{2}{8} \cdot 0 + \frac{3}{8} \cdot 0 + \frac{3}{8} \cdot E(c3) \right) \right) \\
 &= \frac{8}{9} \times \left(1.0 - \left(0 + 0 + \frac{3}{8} \cdot 0.918 \right) \right) \\
 &= \frac{8}{9} \times (1.0 - 0.344) \\
 &= \frac{8}{9} \times 0.656 = 0.583
 \end{aligned}$$

Split Information (termasuk missing):

$$\begin{aligned}
 \text{SplitInfo}(S, C) &= - \sum_{i=1}^4 \frac{|S_i|}{|S|} \log_2 \frac{|S_i|}{|S|} \\
 &= - \left(\frac{2}{9} \log_2 \frac{2}{9} + \frac{3}{9} \log_2 \frac{3}{9} + \frac{3}{9} \log_2 \frac{3}{9} + \frac{1}{9} \log_2 \frac{1}{9} \right) \\
 &= 1.890
 \end{aligned}$$

Gain Ratio:

$$\text{GainRatio}(S, C) = \frac{\text{Gain}(S, C)}{\text{SplitInfo}(S, C)} = \frac{0.583}{1.890} = 0.308$$

4. SplitInformation dan Gain Ratio Atribut A

Dalam dataset S, semua 9 instance memiliki nilai A = a3.

Kondisi Awal (sebelum missing value C diisi):

- Semua instance: A = a3
- $\text{SplitInfo}(S, A) = -\frac{9}{9} \log_2(1) = 0$
- $\text{GainRatio}(S, A)$ tidak terdefinisi (pembagian dengan 0)

Setelah missing value di C diisi dengan c1:

Pengisian missing value di Atribut C **TIDAK mempengaruhi** Atribut A karena:

- Distribusi nilai A tetap sama (semua = a3)
- $\text{SplitInfo}(S, A)$ tetap = 0
- $\text{GainRatio}(S, A)$ tetap tidak terdefinisi

Kesimpulan: Nilai SplitInformation untuk Atribut A tetap 0, sehingga Gain Ratio tetap tidak terdefinisi. Pengisian missing value di C tidak mengubah distribusi nilai di A.

5. Pencabangan dari Root C dengan Algoritma C4.5

Berdasarkan algoritma C4.5, instance dengan missing value didistribusikan ke semua cabang dengan bobot proporsional.

Distribusi nilai C: c1 (2 instance), c2 (3 instance), c3 (3 instance), missing (1 instance)

Total instance dengan nilai diketahui = 8

Bobot untuk instance 4 (missing value):

- Ke c1: $2/8 = 0.25$
- Ke c2: $3/8 = 0.375$
- Ke c3: $3/8 = 0.375$

Pencabangan dari Root C:

Cabang C = c1:

- Instance 3 (bobot 1.0): B=25, D=d1, Y
- Instance 5 (bobot 1.0): B=26, D=d5, Y
- Instance 4 (bobot 0.25): B=21, D=d4, N

Cabang C = c2:

- Instance 1 (bobot 1.0): B=17, D=d9, N
- Instance 6 (bobot 1.0): B=18, D=d3, N
- Instance 8 (bobot 1.0): B=21, D=d2, N
- Instance 4 (bobot 0.375): B=21, D=d4, N

Cabang C = c3:

- Instance 2 (bobot 1.0): B=19, D=d7, Y
- Instance 7 (bobot 1.0): B=23, D=d8, Y
- Instance 9 (bobot 1.0): B=21, D=d6, N
- Instance 4 (bobot 0.375): B=21, D=d4, N

6. Atribut B dengan Cost Tinggi

Tidak, atribut B masih mungkin terpilih meskipun costnya jauh lebih besar.

Pemilihan atribut berdasarkan rasio $\frac{\text{Gain}(S, \text{Atribut})}{\text{Cost}(\text{Atribut})}$. Atribut B tetap dapat terpilih jika:


- Gain(S, B) sangat tinggi sehingga rasio $\frac{\text{Gain}(S, B)}{\text{Cost}(B)}$ masih lebih besar dari atribut lain
- Atribut lain memiliki gain sangat rendah atau nol (seperti A yang semua nilainya sama)

Contoh: Jika $\text{Gain}(S, B) = 0.9$, $\text{Cost}(B) = 100 \rightarrow \text{rasio} = 0.009$. Jika $\text{Gain}(S, A) = 0.001$, $\text{Cost}(A) = 1 \rightarrow \text{rasio} = 0.001$. Maka B tetap terpilih.

Kesimpulan: Cost tinggi tidak mengeliminasi atribut jika gain-nya cukup besar untuk membuat rasio tetap kompetitif.

7. Post-Pruning dengan Menghapus Atribut A1

Dari pohon keputusan yang diberikan, struktur lengkapnya:



Atribut A memiliki nilai: a1_1, a1_3 (di root) dan a2_1, a2_2 (di subtree).

Interpretasi "menghapus atribut A1 sebagai prekondisi":

Jika menghapus node split berdasarkan $a1_1$ (menghapus cabang $A = a1_1$), maka:

- Cabang $a1_1 \rightarrow Y$ dihapus
- Pohon tersisa hanya cabang $a1_3$ dengan subtree-nya
- Instance yang tadinya masuk ke cabang $a1_1$ sekarang harus direklasifikasi menggunakan sisa pohon atau berdasarkan mayoritas

Hasil pruning:

Setelah menghapus prekondisi $A = a1_1$, pohon menjadi lebih sederhana tetapi kehilangan kemampuan untuk mengklasifikasikan instance dengan $A = a1_1$. Struktur baru hanya memiliki cabang $A = a1_3$ yang kemudian bercabang lagi berdasarkan nilai $a2_1$ dan $a2_2$.

Kesimpulan: Pruning mengurangi kompleksitas pohon (menghapus 1 leaf dan 1 edge) tetapi mengurangi cakupan karena instance dengan $A = a1_1$ tidak lagi memiliki path klasifikasi yang jelas.

To be Continued...